

IMDb-Bewertungen verstehen und vorhersagen

Mustafa Takirtas · KI-Programmierung · OTH Regensburg

Datensatz: IMDb 5000 Movie Dataset (Kaggle) [1] · Zielvariable: imdb_score · Aufgabe: Regression

1 Grundinformationen

- 4998 Filme, 28 Spalten, 45 Duplikate entfernt
- 16 numerisch, 12 textuell (Metadaten, Reichweite)
- imdb_score: 1,6-9,5 · MW 6,44 · Median 6,60 · 0 NaN
- Verteilung leicht linksschief (MW < Median)

2 Forschungsfrage

- Welche Merkmale hängen mit dem IMDb-Score zusammen, und wie gut lässt er sich vorhersagen?
- Ansatz: EDA → Korrelation → Split → Modellvergleich

3 Explorative Datenanalyse

- 85,5 % der Scores liegen zwischen 5 und 8.
- Die Verteilung ist linksschief (Schiefe = -0,74).
- Fehlende Werte: gross 17,5 %, budget 9,7 %.
- imdb_score enthält keine fehlenden Werte.




Abb. 1 - Verteilung der IMDb-Bewertungen

Stärkste lineare Zusammenhänge




Abb. 2 - Pearson-Korrelationen der numerischen Merkmale

4 Korrelationsanalyse

- Stärkste lineare Zusammenhänge (Pearson):
 - Nutzerstimmen (0,41)
 - Kritikerrezensionen (0,31)
 - Nutzerrezensionen (0,29)
- budget: kein relevanter linearer Zusammenhang (0,03).
- title_year: leicht negativ (-0,21); spätere Jahre gehen mit etwas niedrigeren Scores einher. Keine Kausalaussage.

5 Modell & Bewertung

- Vorverarbeitung: Duplikate entfernt; vollständige numerische Fälle → 3768 Filme, 15 Merkmale
- StandardScaler für Linear; RF benötigt keine Skalierung
- Split 60/20/20: 2260/754/754 (seed=42)
- Validierung R^2 : Linear 0,32 · RF 0,56
- Final: Random Forest (beste Validierung)
n_estimators=100 · max_depth=None
min_samples_split=2 · random_state=42
- Test: R^2 0,51 · MAE 0,52 · RMSE 0,71 Scorepunkte
- Train R^2 0,93 → Überanpassung; Val 0,56 ≈ Test 0,51

Vorhergesagt vs. tatsächlich (Random Forest)




Abb. 3 - Vorhergesagt vs. Tatsächlich

6 Fehlschläge, Lernmomente & Ausblick

- Nur numerische Merkmale; vollständige Fallanalyse verliert 24,6 % der Filme.
- num_voted_users und gross entstehen erst nach Veröffentlichung: keine Pre-Release-Prognose.
- Nächste Schritte: kategoriale Merkmale, Imputation und Kreuzvalidierung.

7 Fazit

- Nutzerstimmen: stärkster linearer Zusammenhang.
- Random Forest besser als lineare Basis; Test- R^2 = 0,51.
- Post-Release-Merkmale: keine Vorabprognose.

8 Quellen (MLA, inkl. KI-Nutzung)

[1] IMDB 5000 Movie Dataset. Kaggle. kaggle.com/datasets/carolzhangdc/imdb-5000-movie-dataset. Zugriff: 23. Juni 2026.

[2] Anthropic. Claude [KI-Sprachmodell]. claude.ai. Unterstützung bei Programmierung und Konzeptklärung.

[3] Pedregosa, F., et al. Scikit-learn: Machine Learning in Python. JMLR, Bd. 12, 2011, S. 2825-30.

[4] Waskom, M. seaborn: statistical data visualization. JOSS, Bd. 6, Nr. 60, 2021, S. 3021.